



Data Journal

Instructions

O dataset representa vendas de um retalhista multi-categoria nos EUA (Superstore), com 9.994 transações entre 2014 e 2017, cobrindo as categorias Furniture, Office Supplies e Technology.

Stakeholder: Gestor de Operações e Inventário

Business Question: Quais os padrões de procura por categoria e região, e como podem informar decisões de reposição de stock?

Date: Aug 23	Course/topic: ASK fase
Prompt:	(1) Categorias com mais vendas (2) Sazonalidade mensal (3) Produtos com menor rotação (4) Diferenças regionais
Journal Entry:	Ao escrever a pergunta de negócio antes de abrir o dataset, percebi que sem definir isto primeiro, corria o risco de analisar tudo um pouco e não responder a nada de forma útil. A parte mais difícil foi decompor a pergunta principal em sub-perguntas específicas às colunas reais do dataset (Category, Region, Sub-Category) em vez de ficar em perguntas vagas tipo "que insights existem". Obrigou-me a pensar já na estrutura SQL antes de tocar nos dados, o que acredito que vai poupar tempo na fase de Analyze. Também percebi que "Product Name" tem demasiada amplitude para uma análise útil de rotação (quase 1850 produtos distintos) — decidi usar Sub-Category como nível de agregação, mais acionável para decisões de reposição.
Other thoughts or questions:	Dataset é só EUA (não generaliza a outros mercados), termina em 2017 (desatualizado para tendências atuais), não tem dados reais de stock/inventário — só vendas, o que limita a análise de reposição a uma aproximação via rotação de vendas.



Date: Aug 23	Course/topic: PREPARE fase
Prompt:	Que limitações do dataset identifiquei logo à partida (mercado, período, granularidade)? Que suposições estou a assumir sobre a fonte dos dados e porque são razoáveis?
Journal Entry:	Confirmei 9.995 linhas e 21 colunas, período de Order Date entre 2/jan/2014 e 11/dez/2017. Category tem 3 valores únicos, Region tem 4. Encontrei 0 valores em branco na folha, utilizei formatação condicional A estrutura real bateu certo com o que esperava. Protegi a folha com os dados originais e apenas alterar a nova folha.
Other thoughts or questions:	

Date:	Course/topic: PROCESS fase
Prompt:	Que decisões de limpeza tomei (duplicados, nulos, tipos de dados) e qual foi a justificação para cada uma? Se repetisse este processo amanhã, o que faria diferente?
Journal Entry:	Ao analisar qual data type eram as colunas percebi que nas colunas de order date e ship date, estavam em formato MDA(EUA) e não em DMA. Pelo o que transformei as datas em DMA. As restantes colunas estavam no formato correto para análise. Revi através da validação de dados(lista) as colunas de region e category se não apresentavam formatações diferentes (ex: east, East).Criei 2 colunas (Order month e Shipping days) de modo a perceber o mês de cada order para ser mais fácil para depois ver a sanolidade e o tempo de demora entre o dia da ordem e o ship date). Ao transferir o csv para o SQL, reparei que estava a dar erro, pelo que nas opções avançadas tive de alterar o delimitador de , para ; e header row to skip de 0 para 1. Houve dificuldades na exportação para SQL pois havia micro falhas (dados a mais e linhas fantasma). Removi duplicados no excel.
Other thoughts or questions:	Da próxima vez, confirmar COUNTA() logo a seguir a arrastar fórmulas e antes de exportar — teria evitado 2 rondas de correção. Também aprendi que exportação de CSV em PT usa ; por defeito, o que o BigQuery não assume automaticamente — verificar isto logo à partida em projetos futuros.



Date:	Course/topic: ANALYSE fase
Prompt:	CATEGORIAS COM MAIS VENDAS
Journal Entry:	1. Usei este código para responder à 1ª sub-questão, precisei de seleccionar a colunas “Category”, posteriormente somar as colunas de SALES e PROFIT e atribuir um novo nomes/s. 2. De seguida agrupar os dados pela categoria e ordenar a Soma das Sales de forma descendente para ser visível a categoria com mais vendas. 3. Através desta análise conseguimos perceber as vendas e lucro por categoria de produtos por uma questão de melhorar a visibilidade e estética dos dados decidi usar a função ROUND para pôr em 2 casas decimais. Arquivo Editar Executar Ferramentas 1 2 3 4 5 6 7 8 9 10 11 12 SELECT Category, ROUND(SUM(Sales), 2) AS Total_Sales, ROUND(SUM(Profit), 2) AS Total_Profit FROM `project-9c439003-6f06-45d6-91b.Retail_Analysis.superstore_sales` GROUP BY Category ORDER BY Total_Sales DESC Consulta concluída Usando cota de processamento sob demanda >1 Resultados da consulta Informações do job Resultados Visualização JSON Detalhes Linha Category Total_Sales Total_Profit 1 Technology 834227.09 145046.21 2 Furniture 741999.8 18451.28 3 Office Supplies 719047.02 122490.78



Other thoughts or questions:

Percebi ao fazer este código que por questões de estética, haveria a necessidade de apresentar os resultados com 2 casa decimais.

Date:	Course/topic: ANALYSE fase
Prompt:	SAZONALIDADE MENSAL
Journal Entry:	1. Para responder à 2ª sub-pergunta, escolhi a coluna do mês (Order Month) e somei todos os valores de venda (SUM(Sales)), arredondando o resultado para 2 casas decimais. 2. Agrupei as vendas individuais por mês. Sem isso, o SQL não saberia que deve somar os valores separadamente para cada mês. 3. Decidi por fim ordenar os dados pela coluna Order Date pois essa tem os dias enquanto a Order Month só tem mês e ano. 4. O foco foi transformar milhares de linhas de vendas individuais em apenas 48 linhas resumidas, permitindo identificar rapidamente se as vendas sobem ou descem em épocas específicas do ano (sazonalidade).



```
1 SELECT `Order Month`,
2
3 ROUND(SUM(Sales), 2) AS Total_Sales
4
5 FROM `project-9c439003-6f06-45d6-91b.Retail_Analysis.superstore`
6
7 GROUP BY `Order Month`
8
9 ORDER BY MIN(`Order Date`);
10
```

✓ Consulta concluída

>I Resultados da consulta

Chat

View all jobs

Informações do job

Resultados

Visualização

JSON

D

Linha	Order Month	Total_Sales
1	2014-01	14236.89
2	2014-02	4519.89
3	2014-03	55691.01
4	2014-04	28178.56
5	2014-05	23648.29
6	2014-06	34595.11
7	2014-07	33946.39
8	2014-08	27909.47
9	2014-09	81777.36
10	2014-10	31453.39
11	2014-11	78628.72

Exportei esses resultados para o Excel para ver através de um gráfico de linhas as vendas por mês e a sua consequente variação.





Other thoughts or questions:

A dificuldade aqui foi perceber que tinha de usar a coluna de order date e não a de order month para os resultados serem mais fiáveis e usar a função ORDER BY MIN para começar pela data mínima quando apresentar resultados.

Date:	Course/topic: ANALYSE fase
Prompt:	CATEGORIAS/PRODUTOS COM MENOS ROTAÇÃO
Journal Entry:	1. Para responder à 3ª sub-pergunta, utilizei a coluna de Sub-Category para analisar as sub-categorias(tipos de produtos) com menor rotação. 2. Na segunda linha conta quantos IDs de pedido únicos existem para cada subcategoria. 3. Criei 2 colunas de somas de sales e de quantidade para depois facilitar no cálculo seguinte. 4. ROUND(SUM(Quantity) / COUNT(DISTINCTOrder ID), 2) AS Avg_Qty_Per_Order: Calcula a média de itens por pedido (divisão da quantidade total pelo número de pedidos únicos) e arredonda para 2 casas decimais. 5. Agrupei todos os cálculos anteriores por subcategoria, para que as somas e contagens sejam individuais para cada uma (ex: Cadeiras, Papel, etc.) e ordenei o resultado final pelo nº de ordens de forma ascendente. Isso coloca as subcategorias com a menor saída média por pedido no topo da lista.
Other thoughts or questions:	A parte mais complexa foi perceber que tinha de contar apenas pedidos únicos através do ID Resolvi fazer esta análise por categoria e não por produto individual pois queria demonstrar de uma forma mais geral.

Date:

Course/topic: ANALYSE fase



Prompt:	DIFERENÇAS REGIONAIS																									
Journal Entry:	1. Para responder à 4ª sub pergunta tive de selecionar a coluna das Regiões. 2. De seguida queria que fossem apresentados os dados de vendas totais, quantidade de pedidos únicos e a média de tempo (em dias) que um produto leva para ser enviado após o pedido ter sido feito. 3. Finalmente agrupar pelas Regiões e ordenar de forma decrescente as vendas totais por região. <pre>1 SELECT Region, 2 3 ROUND(SUM(Sales),2) AS Total_Sales, 4 COUNT(DISTINCT `Order ID`) AS Total_Orders, 5 ROUND(AVG(`Shipping Days`), 2) AS Avg_Shipping_Days 6 7 FROM `project-9c439003-6f06-45d6-91b.Retail_Analysis.superstore_sales` 8 9 GROUP BY Region 10 ORDER BY Total_Sales DESC; 11</pre> ✓ Esta consulta vai processar 379,21 KB quando executada. Usando cota de processamento sob demanda >I Resultados da consulta ChatView all jobsSalvar res Informações do jobResultadosVisualizaçãoJSONDetalhes da execução <table><tr><th>Linha</th><th>Region</th><th>Total_Sales</th><th>Total_Orders</th><th>Avg_Shipping_Days</th></tr><tr><td>1</td><td>West</td><td>725457.8</td><td>1611</td><td>3.93</td></tr><tr><td>2</td><td>East</td><td>678664.45</td><td>1401</td><td>3.91</td></tr><tr><td>3</td><td>Central</td><td>500130.47</td><td>1175</td><td>4.06</td></tr><tr><td>4</td><td>South</td><td>391021.19</td><td>822</td><td>3.96</td></tr></table>	Linha	Region	Total_Sales	Total_Orders	Avg_Shipping_Days	1	West	725457.8	1611	3.93	2	East	678664.45	1401	3.91	3	Central	500130.47	1175	4.06	4	South	391021.19	822	3.96
Linha	Region	Total_Sales	Total_Orders	Avg_Shipping_Days																						
1	West	725457.8	1611	3.93																						
2	East	678664.45	1401	3.91																						
3	Central	500130.47	1175	4.06																						
4	South	391021.19	822	3.96																						
Other thoughts or questions:	A diculdade aqui passou por perceber quais os dados que queria representar e decidi que as vendas,ordens totais e media de tempo que um produto leva para ser enviado após o pedido ter sido feito eram os critérios essências para a análise.																									

Date:	Course/topic: SHARE fase
-------	--------------------------



Prompt:	Gráfico 1 — Categorias: Gráfico 2 — Sazonalidade: Gráfico 3 — Rotação por sub-categoria: Gráficos 4 — Regiões:
Journal Entry:	Gráfico 1 — Categorias: Technology lidera em vendas (834k) e lucro (145k). Furniture vende quase tanto quanto Office Supplies (742k vs 719k) mas lucra 13x menos (18k vs 122k) — indica problema de margem/descontos, não de falta de procura. Gráfico 2 — Sazonalidade: Picos de vendas consistentes em setembro e novembro/dezembro nos 4 anos analisados (2014-2017), com o máximo absoluto em novembro de 2017 (118k). Janeiro é sistematicamente o mês mais fraco, sendo este um padrão sazonal previsível. Gráfico 3 — Rotação por sub-categoria: Copiers e Machines têm baixa frequência de compra mas alto valor (149k e 189k) sendo estes considerados produtos de nicho a manter. Supplies, Envelopes, Labels e Fasteners (combinam baixa frequência com baixo valor — candidatos reais a reavaliação de stock. Phones e Binders têm alta frequência e alto valor — produtos-chave, garantir disponibilidade constante. Gráficos 4 — Regiões: West lidera em vendas (725k) e volume de encomendas (1.611). Central tem o tempo médio de envio mais lento das 4 regiões (4,06 dias vs ~3,9-3,96 nas restantes) — diferença pequena mas consistente, possível sinal a investigar.
Other thoughts or questions:	Optei por um gráfico de dispersão no Gráfico 3 em vez de barras, porque o objetivo era cruzar duas variáveis (frequência e valor) ao mesmo tempo — barras só mostrariam uma de cada vez e esconderiam os quadrantes. Simplifiquei a linguagem em todos os achados para evitar termos técnicos (facilitar leitura do stakeholder)

Date:	Course/topic: ACT fase
Prompt:	Que recomendações de negócio consegui justificar diretamente com os dados analisados? O que ficou por explorar, e é uma limitação aceitável ou algo a resolver antes de publicar?



Journal Entry:	Consegui ligar cada recomendação a um número concreto, não a uma sensação. Furniture precisa de rever descontos porque a margem é 13x mais baixa que as outras categorias, apesar de vender quase o mesmo que Office Supplies. Vale a pena reforçar stock antes de setembro e novembro, porque o pico repete-se nos 4 anos, não é um palpite. E há 4 sub-categorias (Fasteners, Labels, Envelopes, Supplies) que vendem pouco e são pouco pedidas — candidatas a reduzir. Já Copiers e Machines parecem parecidos à primeira vista, mas são o oposto: vendem pouco em quantidade, mas cada venda vale muito. Não podem levar o mesmo tratamento.
Other thoughts or questions:	A parte mais difícil foi não simplificar demais. Tinha identificado só 2 sub-categorias fracas (Supplies e Envelopes) e ia avançar assim — só ao voltar a olhar para os números é que vi que Fasteners e Labels estavam escondidas, porque tinham frequência "normal", mas vendas muito baixas. Se não tivesse voltado atrás, a recomendação ficava incompleta. Também custou resistir à tentação de escrever "resolver o problema do shipping em Central" — os dados só mostram que é mais lento, não porquê, por isso a recomendação certa é investigar, não prometer solução.
